

¿Haciendo dinero con el aprendizaje de máquinas?

Ana Rojas, Juan Rincón, Julián Delgado y Mario Mercado

Universidad de los Andes
Facultad de Economía
Maestría en Economía Aplicada
Bogotá D.C, Colombia
2025

1. Introducción

En el presente documento¹ se tiene como objetivo explorar técnicas de aprendizaje automático para predecir los precios de las viviendas en el barrio de Chapinero en Bogotá-Colombia, utilizando una base de datos proveniente de la plataforma inmobiliaria de venta de viviendas nuevas y usadas Properati. Para ello, se implementan modelos supervisados, como Random Forest y regresiones penalizadas. Además, se evalúa la capacidad predictiva de los diferentes enfoques y se identifican las características que explican el modelo de precios de las unidades inmobiliarias.

1.1 Contexto

El sector de la construcción en Colombia es uno de los mayores dinamizadores de la economía creando encadenamientos hacia adelante y atrás, esto representando un 4.3% del Producto Interno Bruto, dentro de este las edificaciones representan un 2.2% (BBVA Research, 2025). Las viviendas actualmente hacen parte fundamental del mayor gasto que puede hacer una familia a lo largo de su ciclo de vida, esto con el fin de satisfacer el deseo de mejorar el bienestar dentro del núcleo familiar.

¹ Para ver la evidencia de lo demostrado en este documento, diríjase a https://github.com/juanrincon6/Taller_3_Big_Data

1.2 Antecedentes

La literatura sobre el comportamiento de los precios de la vivienda dada una serie de características es amplia, estudios a nivel teórico como los de Rosen (1974) establece que para que se pueda llevar a cabo las transacciones de compra y venta de propiedades inmobiliarias, los consumidores y productores en base en sus comportamientos racionales, tomarán sus decisiones de acuerdo a la localización y cantidad del bien en cuestión, esto quiere decir que para que se pueda llevar a cabo la transacción comercial del bien (en este caso una vivienda). Los precios hedónicos es una de las técnicas más usadas para la valoración de los bienes para los cuales no existe un mercado en cuestión (non-market good) o de preferencia reveladas, siguiendo a Pearce et al. (2006); Atkinson et al. (2018) definen el método de los precios hedónicos como aquel que estima el valor de un bien de tipo no comercial teniendo en cuenta el comportamiento de la oferta y demanda de este, en este caso específico del estudio referente al mercado inmobiliario.

2. Datos

Para desarrollar la base de datos destinada a la estimación de modelos predictivos de precios inmobiliarios, se inició con la importación de cuatro archivos al software R. Posteriormente, se organizó la información en una carpeta denominada *store*, donde los archivos fueron almacenados en formato estándar de R (*rds*), facilitando la eficiencia computacional y la reproducibilidad del análisis.

Esta estructura permite entrenar múltiples modelos algorítmicos con el objetivo de predecir los precios de las unidades inmobiliarias en Chapinero. La integración de fuentes externas y el procesamiento de datos facilitarán la construcción de un modelo robusto, capaz de capturar las características clave que influyen en el valor de las propiedades.

2.1 Descripción de los datos

El poder de la librería *tidyverse* fue fundamental para la manipulación y preprocesamiento de los datos utilizados en la estimación de modelos predictivos de precios inmobiliarios. Su aplicación permitió una limpieza eficiente de la base de datos, abordando valores faltantes y atípicos en las variables relacionadas con las características estructurales de las propiedades y su entorno.

Posteriormente, se realizó una selección de las variables más relevantes, tanto desde una perspectiva teórica como empírica, asegurando que las características clave influyeran en la precisión de los modelos de estimación de precios. Aplicando esta misma lógica al conjunto de datos de entrenamiento (*training set*). Esto permitió la consolidación de una base de datos final, optimizada para el entrenamiento y evaluación de los modelos algorítmicos.

2.2 Análisis descriptivo de los datos

De acuerdo con la tabla 1, se presentan las estadísticas descriptivas de las variables utilizadas en los modelos algorítmicos predictivos de precios inmobiliarios. Se observa que las variables continuas tienen una distribución adecuada, sin señales de valores faltantes (*missing values*) ni valores atípicos (*outliers*). En cuanto a las variables categóricas, que en su mayoría son dicotómicas, se encuentran dentro de los rangos esperados y no presentan anomalías significativas, lo que las hace útiles para el entrenamiento de los modelos de estimación.

Tabla 1. Estadísticas descriptivas del modelo hedónico de precios de viviendas

Variable	Mínimo	Máximo	Mediana	Media
price	300,000,000	1,650,000,000	560,000,000	654,500,000
surface_covered	2	1336	108	113.3
rooms	1	11	3	3.004
bedrooms	0	11	3	3.145
bathrooms	1	13	2	2.653
tiene_remodelado	0	1	0	0.121
tiene_lujoso	0	1	0	0.1875
tiene_bbq	0	1	0	0.1707
tiene_balcon	0	1	0	0.2043
tiene_terraza	0	1	0	0.299
tiene_vista	0	1	0	0.2379
tiene_club_house	0	1	0	0.0392
tiene_chimenea	0	1	0	0.2339
distancia_parque	0.991	3,061.29	137.644	157.534
distancia_bus	4.021	3,834.87	779.122	943.503
distancia_avenida_principal	0	1,974.75	204.19	276.76
distancia_universidad	3.195	4,338.04	1,017.70	1,067.08
distancia_policia	1.529	2,165.18	681.8	718.269
distancia_restaurant	1.171	1,541.50	185.362	219.708
distancia_colegio	0.5788	1,646.78	3,427.274	3,812.051


Nota. Elaboración propia

Tabla 2. Descripción de las variables del modelo hedónico de precios de viviendas


Variable	Tipo	Descripción
surface_covered	Numérica	Área construida de la vivienda (en metros cuadrados).
rooms	Numérica	Número total de habitaciones.
bedrooms	Numérica	Número de habitaciones destinadas a dormitorio.
bathrooms	Numérica	Número total de baños.
property_type	Catórica	Tipo de propiedad (ej. apartamento o casa).
tiene_remodelado	Dummy	Indica si la propiedad ha sido remodelada (1 = sí, 0 = no).
tiene_lujoso	Dummy	Indica si el inmueble tiene acabados de lujo (1 = sí, 0 = no).
tiene_bbq	Dummy	Indica si el inmueble cuenta con zona BBQ (1 = sí, 0 = no).
tiene_balcon	Dummy	Indica si la propiedad tiene balcón (1 = sí, 0 = no).
tiene_terraza	Dummy	Indica si la propiedad tiene terraza (1 = sí, 0 = no).
tiene_vista	Dummy	Indica si la propiedad tiene vista panorámica (1 = sí, 0 = no).
tiene_club_house	Dummy	Indica si el conjunto tiene club house o zonas sociales (1 = sí, 0 = no).
tiene_chimenea	Dummy	Indica si la propiedad cuenta con chimenea (1 = sí, 0 = no).
distancia_parque	Numérica	Distancia en metros al parque más cercano.
distancia_bus	Numérica	Distancia en metros a la estación de transporte público más cercana.
distancia_avenida_principal	Numérica	Distancia en metros a la avenida principal más cercana.
distancia_universidad	Numérica	Distancia en metros a la universidad más cercana.
distancia_policia	Numérica	Distancia en metros a la estación de policía más cercana.
distancia_restaurant	Numérica	Distancia en metros al restaurante más cercano.
distancia_colegio	Numérica	Distancia en metros al colegio más cercano.

Nota. Elaboración propia

Mapa de estaciones de Transmilenio en Bogotá



Mapa de universidades en Bogotá



Nota. Elaboración propia

Dentro las características del modelo de precios hedónicos, los features como estaciones de Transmilenio y universidades son determinantes en la explicación de los precios de las unidades inmobiliarias, esto quiere decir que las personas tienden a preferir este tipo de viviendas que reducen costos de transportes o desplazamiento, siendo este una gran explicación por la que el negocio inmobiliario puede generar altos rendimientos financieros en la compra y venta de estos.

3. Modelos y resultados

Las fluctuaciones de precios de las viviendas o apartamentos del sector inmobiliario por lo general están relacionadas con el índice de precios al consumidor (IPC), esto quiere decir que una variación de esta variable macroeconómica puede conducir a un comportamiento directo del sector inmobiliario y más relevante es mercados de mayor demanda y oferta por este tipo de bienes como es el caso de Bogotá D.C (Hill, 2011). Por lo tanto, se espera que un modelo no lineal como el de bosques aleatorios o Random Forest² ofrezca un mejor desempeño predictivo. A diferencia de los modelos lineales, que asumen relaciones constantes entre cada variable y el resultado, Random Forest permite capturar interacciones no evidentes y efectos no lineales entre los atributos de las viviendas y sus respectivos precios.

La formulación matemática del modelo de bosques aleatorios se basa en la siguiente ecuación:

$$P_i = f(\text{Area}_i, \text{Bedrooms}_i, \text{Distance to parks}_i) + u_i$$

² Autores como Alonso & Hoyos (2025) y Irizarry (2021) explican que los modelos de bosques aleatorios se basan en mejorar la predicción del algoritmo mediante diferentes estimaciones de tipo individual con el objetivo de promediar estas últimas para buscar estabilidad del modelo.

Tabla 3. Variables más importantes *del modelo de Random Forest*

Variable	Importancia
bathrooms	6.03E+20
distancia_bus	3.23E+20
distancia_universidad	3.22E+20
distancia_colegio	3.00E+20
distancia_parque	2.93E+20
surface_covered	2.93E+20
bedrooms	2.84E+20

Nota. Elaboración propia

Tabla 4. *Modelo de Random Forest*

mtry	splitrule	min.node.size	RMSE	Rsquared	MAE	RMSESD	RsquaredSD	MAESD
3	variance	1	180962276	0.6759298	119638382	4096934	0.0137256	1867665
3	variance	5	183213478	0.6687985	122426532	3999324	0.0129272	1947628
5	variance	1	175949536	0.6861529	111195367	4403131	0.014485	2115986
5	variance	5	177791769	0.6805315	113969291	4249737	0.0138917	2036743
7	variance	1	176046706	0.6841062	110589437	4514175	0.0148754	2287120
7	variance	5	177231678	0.6806788	112720350	4537733	0.0148818	2280792

Nota. Elaboración propia

En el marco del proyecto de predicción, que busca estimar precios de propiedades, se desarrolló y comparó con múltiples modelos de *machine learning*. Entre ellos, se destacaron los modelos basados en árboles, particularmente el modelo de Random Forest, que finalmente resultó ser el más preciso entre los modelos probados.

En primer lugar, la preparación del entorno y los datos fue sumamente importante con el fin de que sea reproducible. Se cargaron las librerías necesarias y se configuraron las rutas dinámicamente según el usuario para facilitar la portabilidad del script entre diferentes entornos de trabajo. Los datos ya estaban previamente tratados y el entorno limpio. Se importaron los datasets finales: train y test, con información relevante sobre características estructurales y de entorno de las propiedades.

Aunque los conjuntos train y test venían predefinidos, fue necesario aplicar una partición interna adicional sobre train mediante validación cruzada (cross-validation) para garantizar una estimación robusta del rendimiento real del modelo y evitar sobreajuste. Es decir, se dividió el conjunto de entrenamiento en 10 particiones, donde en cada iteración 9 sirven para entrenar y 1 para validar. Este enfoque mitiga el riesgo de overfitting y permite evaluar consistentemente modelos incluso con estructuras complejas como random forest.

Para comenzar se entrenó un modelo base con rpart, un árbol de decisión sencillo, que sirve como línea base interpretable y de rápida ejecución. Se analizó el árbol para entender cómo el modelo jerarquiza variables y cuáles tienen mayor poder explicativo. Si bien el árbol entregó resultados razonables, mostró limitaciones en capacidad predictiva, al estar limitado por su naturaleza secuencial y poco robusta frente a ruido.

El siguiente paso fue entrenar un modelo de random forest con ranger, una implementación eficiente en R, que permite introducir múltiples árboles en paralelo y reducir la varianza de las predicciones y se implementaron unos hiperparámetros acotados para optimizar el desempeño sin incurrir en sobreajuste. Se eligió mtry moderado para balancear sesgo y varianza, y se probó min.node.size bajo para permitir complejidad, pero sin llegar a overfit.

Splitrule = "variance" es ideal para regresión, maximizando la reducción de error. Se empleó el RMSE (Root Mean Squared Error) como métrica principal, ya que penaliza errores grandes y es sensible a la escala de los precios. Este modelo resultó ser el más preciso de los evaluados, con el menor RMSE validado por CV.

Una vez diseñado el modelo bajo especificaciones, se realizó la predicción sobre el conjunto de prueba (test), y se exportaron los resultados. Se identificó que el modelo de Random Forest logró capturar relaciones no lineales complejas entre variables estructurales y de entorno, sin sobreajustarse, gracias a una validación cruzada robusta y un grid de hiperparámetros

cuidadosamente diseñado. La combinación de interpretabilidad (en los árboles) y robustez (en los ensembles) permitió alcanzar el mejor desempeño predictivo del proyecto.

4. Conclusiones y recomendaciones

El estudio demuestra que los modelos de aprendizaje automático, particularmente Random Forest, ofrecen una herramienta poderosa para la predicción de precios de viviendas en Chapinero. La selección y limpieza de datos permitieron construir un conjunto de entrenamiento sólido, asegurando una estimación precisa de los factores que influyen en los precios inmobiliarios. Se identificó que variables como la cantidad de baños, la superficie cubierta y la proximidad a universidades y estaciones de transporte tienen una importancia significativa en la determinación del valor de las propiedades. Además, el uso de validación cruzada garantizó que el modelo mantuviera una buena capacidad predictiva sin incurrir en problemas de sobreajuste.

Si bien el modelo presenta un desempeño robusto, existen oportunidades para mejorar la interpretación de los resultados y optimizar la selección de variables. La incorporación de información macroeconómica, como el Índice de Precios al Consumidor (IPC), podría enriquecer el análisis y capturar dinámicas más amplias del mercado inmobiliario. Asimismo, explorar otros enfoques, como redes neuronales o regresiones penalizadas, podría complementar las estimaciones y ofrecer comparaciones más detalladas. Este estudio subraya el valor del aprendizaje automático en la toma de decisiones inmobiliarias, abriendo la puerta a futuras aplicaciones en el análisis del sector.

5. Referencias

- [1]. Alonso, J. C. (2024). *Introducción al modelo clásico de regresión para científicos de datos en R*. Editorial Universidad Icesi. <https://doi.org/10.18046/EUI/bda.h.4>
- [2]. Alonso, J. C., & Camilo Hoyos, C. (2025). *Una introducción a los modelos de clasificación empleando R*. Editorial Universidad Icesi. <https://doi.org/10.18046/EUI/bda.h.5>
- [3]. Alonso, J.C., Largo, M.F., & Camilo Hoyos, C. (2025). *Una introducción a los modelos de clustering empleando R*. Editorial Universidad Icesi. <https://doi.org/10.18046/EUI/bda.h.6>
- [4]. BBVA Rearch. (2025). Situación inmobiliaria 2025. BBVA.
- [5]. Harrison, D. Jr., & Rubinfeld, D. L. (1978). Hedonic housing prices and the demand for clean air. *Journal of Environmental Economics and Management*, 5(1), 81-102. [https://doi.org/10.1016/0095-0696\(78\)90006-2](https://doi.org/10.1016/0095-0696(78)90006-2)
- [6]. Hill, R. (2011). *Hedonic Price Indexes for Housing*. OECD Statistics Working Papers, No. 2011/01, OECD Publishing. <https://doi.org/10.1787/5kghzxpt6g6f-en>
- [7]. Irizarry, R. A. (2021). *Introducción a la ciencia de datos: Análisis de datos y algoritmos de predicción con R*. Leanpub. <https://rafalab.dfci.harvard.edu/dslibro/>
- [8]. Mendieta López, J. (1999). *Manual de valoración económica de bienes no mercadeables: Aplicaciones de las técnicas de valoración no mercadeables y el análisis costo beneficio y medio ambiente*. Universidad de los Andes, Facultad de Economía, CEDE. <http://hdl.handle.net/1992/8056>
- [9]. OECD (2006). *Cost-Benefit Analysis and the Environment: Recent Developments*. OECD Publishing, Paris. <https://doi.org/10.1787/9789264010055-en>
- [10]. OECD (2018). *Cost-Benefit Analysis and the Environment: Further Developments and Policy Use*. OECD Publishing, Paris. <https://doi.org/10.1787/9789264085169-en>
- [11]. Rosen, S. (1974). Hedonic prices and implicit markets: Product differentiation in pure competition. *Journal of Political Economy*, 82(1), 34–55. <http://www.jstor.org/stable/1830899>